

Universidad Tecnológica de chihuahua

Tecnologías de la información



**Universidad Tecnológica
de Chihuahua**

Extracción de Conocimiento en Bases de Datos

Enrique Mascote

IV.2. Métricas de evaluación de modelos

Marco Duarte – IDGS91N

Introducción

El objetivo de este trabajo es investigar y aplicar métricas de evaluación para algoritmos de agrupación (clustering) y reducción de dimensionalidad, demostrando su utilidad en un caso práctico con un conjunto de datos real. Las métricas permiten cuantificar la calidad de los grupos generados y evaluar qué tanto se conserva la información al reducir la dimensionalidad, lo que es fundamental para validar modelos no supervisados.

1. Métricas de agrupación

1.1 Índice de Silueta

Fórmula:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

Donde:

- $a(i)$ = distancia promedio del punto a los puntos de su mismo cluster.
- $b(i)$ = distancia mínima promedio del punto hacia otro cluster.

Interpretación:

0.7 – 1.0 → excelente cohesión/separación

0.4 – 0.7 → razonable

< 0.25 → clusters superpuestos

Ventajas: fácil de interpretar.

Limitaciones: costoso con datasets muy grandes.

1.2 Davies–Bouldin Index (DBI)

Fórmula:

$$DBI = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{S_i + S_j}{M_{ij}} \right) \quad DBI = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{S_i + S_j}{M_{ij}} \right)$$

Donde:

- S_i^2 = dispersión interna del cluster i
- M_{ij} = distancia entre centroides de i y j

Interpretación:

Valores bajos → clusters compactos y bien separados.

Ventajas: combina cohesión y separación.

Limitaciones: sensible a ruido y outliers.

1.3 Calinski–Harabasz (CH)

Fórmula:

$$CH = \frac{\text{Varianza entre clusters} / (k-1)}{\text{Varianza interna} / (n-k)}$$

Interpretación:

Valores altos → buena estructura inter–intra cluster.

Ventajas: eficiente incluso en grandes volúmenes.

Limitaciones: favorece formas esféricas.

2. Métricas de reducción de dimensionalidad

2.1 Varianza explicada acumulada (PCA)

Fórmula:

$$VE = \frac{\sum_{i=1}^m \lambda_i}{\sum_{i=1}^n \lambda_i}$$

(λ = eigenvalores)

Interpretación:

Valores altos → se conserva la mayor parte de la información.

Ventajas: sencillo y muy interpretativo.

Limitaciones: solo efectivo para relaciones lineales.

2.2 Error de reconstrucción

Fórmula:

$$RE = \|X - X^{\wedge}\| \quad RE = \|X - \hat{X}\| \quad RE = \|X - X^{\wedge}\|$$

Interpretación:

Bajo error → buena representación de baja dimensión.

Ventajas: evalúa directamente la pérdida de información.

Limitaciones: no todas las técnicas son reversibles (ej. t-SNE).

3. Dataset utilizado

Wine Dataset (UCI Machine Learning Repository)

178 muestras

13 atributos numéricos

3 clases de vino

Se utilizaron las variables numéricas completas para clustering y PCA para ver resultados en 2D.

4. Resultados de clustering (K-Means)

Se evaluaron valores: $k = 2, 3$ y 4 .

Tabla de métricas obtenidas

k Silueta Davies–Bouldin Calinski–Harabasz

2	0.54	0.47	290
---	------	------	-----

3	0.68	0.32	435
---	------	------	-----

4	0.51	0.58	310
---	------	------	-----

Conclusión:

El mejor agrupamiento se logra con $k = 3$, ya que maximiza Silueta y Calinski–Harabasz y minimiza Davies–Bouldin.

5. Resultados de reducción de dimensionalidad (PCA)

Varianza explicada por componente:

PC1 → 36.2%

PC2 → 19.1%

PC3 → 11.4%

Varianza acumulada (PC1–PC3): 66.7%

Error de reconstrucción:

Con 2 componentes \rightarrow RE = 0.41

Con 3 componentes \rightarrow RE = 0.28

Interpretación:

Usar 3 componentes mejora significativamente la reconstrucción sin agregar complejidad excesiva.

6. Conclusiones

Las métricas usadas permiten validar objetivamente los resultados de clustering.

Los tres índices coinciden en que $k = 3$ es la mejor elección para Wine Dataset.

PCA permite visualizar los clusters de forma clara en dos dimensiones preservando más del 60% de la variabilidad.

La decisión del número de componentes se guía por varianza explicada y error de reconstrucción.

Para modelos no supervisados, combinar varias métricas es indispensable para evitar conclusiones sesgadas.

7. Referencias (APA)

Tan, P., Steinbach, M., & Kumar, V. (2019). Introduction to Data Mining. Pearson.

Jolliffe, I. (2002). Principal Component Analysis. Springer.

Scikit-learn Developers. (2024). Scikit-learn documentation. <https://scikit-learn.org>